# 索引

## 目的

- 索引通过存储(查找键,数据位置)来快速定位记录
  - 稠密索引:数据位置→记录的位置(页面,槽位)。稠密索引中,每一条记录对应一个索引条目,索引条目中存储了记录的键值和指针。
  - 稀疏索引:数据位置→页面的位置(页面)。稀疏索引中,索引条目只包含部分记录的键值和指针,而不是每一条记录都建立索引。
  - 。 索引一般存储以页面为单位组织(内存索引除外)
- 索引也需要支持并发控制
- 插入记录时, 先插入数据页面, 然后插入索引, 而且两者要保持事务一致性

### 分类


#### 聚集索引与非聚集索引(按物理存储分类)

- 聚集索引:数据按照查找键排序
  - o 按照查找键连续存储,聚集索引上范围查询效率更高,一张表只能有一个
  - 维护增删时需要移动数据文件中的记录, 开销稍大
- 非聚集索引:辅助索引、二级索引
  - 。 一张表可以有多个,数据不一定按照索引列顺序存储
- 例子



## 稠密索引与稀疏索引(按指针记录的粒度分类)

- 稠密索引:索引到数据记录。稠密索引中,每一条记录对应一个索引条目,索引条目中存储了记录的键值和指针。
- 稀疏索引:索引到文件页面。
- 稀疏索引中,索引条目只包含部分记录的键值和指针,而不是每一条记录都建立索引。
- 例子



#### 单级索引与多级索引(按索引层数分类)

• 单级索引

。 一层索引: 如哈希

• 多级索引

○ 索引文件上再建索引,如:B+tree


。 多级索引目的

■ 多层过滤

■ 进一步降低I/O次数

■ 提升查找速度

o 例子



## 主键索引、唯一索引和普通索引(按字段特性分类)

- 主键索引
  - 。 建立在主键字段上的索引
  - 。 一张表最多只有一个主键索引
  - 。 索引列的值不允许有空值
  - 。 例子



# 主键索引

- 唯一索引
  - 。 建立在 UNIQUE 字段上的索引
  - 。 一张表可以有多个唯一索引
  - 。 索引列的值必须唯一, 但是允许有空值

#### 单列索引与多列索引 (按字段个数分类)

- 单列索引
  - 。 建立在单个字段上的索引
- 多列索引
  - 。 建立在多个字段上的索引
- 例子



## 组织表

- ▶ 用B+树索引组织数据页面,数据页面使用顺序组织方式
- > 叶子节点为数据页面
- ▶ 主键上的B+树聚集索引
  - 主键上范围查询时更多连续I/O
  - 插入/删除数据时要维护主索引,开销增大
- > 索引是否回表:回表指的是通过索引找到页面记录才返回结果
  - · Index only scan不回表:仅查找索引列,根据索引就可以返回结果,如学号是否存在
  - Index scan回表:根据索引列查找其他列的内容,如根据学号查找姓名

#### 索引组织表中,按照主键组织数据,数据记录会经常移动,物理位置改变

数据文件	数据记录指针	代表
索引组织表	主键	MySQL、SQLite
堆表	(页面号, 槽号)	PostgreSQL、DB2

## 索引类型

#### > 不同类型索引支持不同的数据类型、条件类型

查询类型	索引类型
点查询 (score=90)	哈希索引、B+树索引
范围查询(score>60)	B+树索引
多列条件查询(gender=male & rating=5)	位图索引
空间范围查询(115.7° <lag<117.4°& 39.4°<long<41.6°)<br="">最近邻查询(KNN)</lag<117.4°&>	多维索引(R树、Quadtree、 KD树)


## > 是否支持持久化、可以否快速恢复

• 内存索引、磁盘索引


## B+树

### B+树索引结构

- > 结构: 平衡多叉查找树
  - 根到所有叶子节点路径长度相同
- ▶ 扇出m:每个节点最多分叉数
  - 子节点数目范围  $\left[\left[\frac{m}{2}\right], m\right]$
  - 查找键数目范围  $\left[ \left[ \frac{m}{2} \right] 1, m 1 \right]$



- ▶ 节点:页面(磁盘索引)
  - 页面缓冲管理器
- > 节点内指针
  - 内部节点:索引页面号
  - 叶子节点:(数据记录页面号,数据记录槽
    - 号)
- ightharpoonup Tree $(P_i) < K_i \le \text{Tree}(P_{i+1})$
- > 扇出加由页面大小和键值大小决定
  - m通常200~300
  - 10亿条记录仅需要4~5层
  - I/O次数少




## 查找算法

点查询

#### ▶ 点查询


- 从根节点逐层加载索引页面到缓冲区,直到叶子节点
- 注意只判断存在性时, 也要访问到叶子节点
- 内部节点存在的键,叶子节点中不一定存在



#### 区间查询

#### > 区间查询 (范围查询)


- 叶节点兄弟之间有指针
- 首先根据查找键查找左端点
- 然后按照节点指针向右线性扫描




#### 删除算法

- 找到待删除索引记录所在叶子节点
- 从叶子节点中删除索引记录
  - 如果节点中键数目大于等于[m/2]-1,则结束

- 如果节点中键数目小于等于[m/2]-2,发生下溢
  - 尝试从兄弟节点借入索引记录,并更新父节点的键值
  - 若兄弟节点无法借入节点,则与兄弟节点合并,并从父节点删除兄弟节点的键值和指针,然后从父 节点拉取下溢节点与兄弟节点之间的查找键
- 叶子节点下溢删除情况(可以从兄弟节点借入索引记录)



• 叶子节点下溢删除情况(无法从兄弟节点借入索引记录)



## 创建索引指导

- 以下是是否在属性 A 上创建索引的主要因素:
  - o 搜索频率:搜索 A 的频率,包括用于评估条件和联接的频率?
  - 更新频率: A 的更新频率(包括插入和删除)?
  - 候选键: A 的值必须是唯一的吗?
  - o 大小:包含 A 的关系有多大?
- 如果满足以下所有条件,则应创建索引:
  - 。 该表包含大量元组(大表示超过 100,000 个)
  - 。 该属性包含广泛的值
  - 。 该属性包含大部分非 null 值
  - 应用程序查询经常在搜索/联接条件中使用该属性
  - o 大多数查询检索一小部分 Tuples (比如 4%)
- 如果满足以下条件之一,则不应创建索引:

- 。 表不包含大量元组
- 应用程序查询很少在搜索/连接条件中使用该属性
- 大多数查询检索超过 4% 的元组
- 应用程序经常更改表内容。
- 维护成本: 如果需要频繁更改, 维护索引的成本可能会很高。
- 例题:考虑表 R(A,B,C,D)和以下信息: A 是主键,不存在其他候选键。大约 B 的不同值的数量是 C 的两倍,并且这个比率不会改变。在针对 R 的每 100 次操作中,有 10 次是插入;10 个是删除,其中 5 个基于 A 的条件,5 个基于条件 B;70次将是选择查询,其中 30 个基于 A 上的条件,20 个基于条件 B 和 20 个基于条件 C;10 将进行更新,其中 5 个基于 B 的条件,5 个基于 C 的条件。所有条件都是相等条件。讨论应该使用哪个属性来构建主索引,以及应该使用哪个属性来构建二级索引。
  - 。 从给定的信息中,可以得出以下内容: 在每 100 次操作中: 45 个需要基于 A 进行检索(10 个插入、5 个删除、30 个选择) 30 个需要基于 B 进行搜索(5 个删除、20 个选择、5 个更新) 25 个需要基于 C 进行搜索(20 个选择,5 个更新) 0 需要根据 D 进行搜索。A 应具有二级索引(具有主索引在 A 上并不能提高效率,因为最多一个元组将满足每个条件)。D 不应有任何索引,因为它不在任何搜索中。B 应该有一个二级索引,C 应该有一个主索引。尽管涉及 B 的所有条件的百分比略大于 C 的百分比,但 Tuples 的数量满足涉及 C 的每个条件是涉及 B 的 2倍,因为 B 的不同值数是C的两倍。这意味着,如果 B 和C 具有二级索引,基于 C 的每个搜索都将费用是每次基于 B 的搜索的两倍。因此在C上拥有主索引将比在B上具有主索引能减小更多花费。
  - 0 ? ? ?